


图 2.1 | 训练验收应检查优化证据，而不只检查“跑完了”

反例已经存在：同一条 9B 运行完成全部采样并存档，却记录了 100 次 NaN 梯度。



建议验证 | 尚未执行

把有限梯度、优化器实际执行、参数变化及保存后恢复共同列为训练验收项。
只有退出成功或存档存在，不足以验收；NaN 的来源仍需定位。


证据：两行各是一条选定的真实分子评估运行，并非模型规模的控制实验。蓝色框记录完成的采样轮次和模型存档；右侧绿／红框分别表示有限／非有限梯度记录。箭头表示依次检查三类证据，数字单位不同，不构成转化率。1.5B/9B 为约 15 亿/90 亿参数；SFT 为监督微调；NaN 为非数值；RL 为强化学习。

判断边界：1.5B 的 60/60 次有限梯度只支持该试跑通过数值有限性检查；9B 的 100/100 次 NaN 使该运行无法凭完成状态通过训练验收。这不证明所有 9B 运行都失败，也没有直接测量模型文件的参数改变量。下方是建议的验收办法，不是已经完成的修复。

来源：15b-fmt10_20260902T175126Z 与 k8sft_20260909T200313Z 的 train.log、episodes.jsonl 和 ckpt 目录。两条均使用真实 acquisition 奖励（预期改进评分）。完整源路径、行号和文件校验值见随附 data/。

图 2.2 | “梯度有限” 还不能替代对实际参数更新的检查

一个通过有限性检查的 9B 运行，裁剪前梯度仍跨越约 10 个数量级。



需要补上的直接证据

同一批输入
↓
裁剪前后梯度与优化器执行
↓
更新前后参数差分
↓
固定输入上的输出变化


建议验证 | 尚未执行

先在固定输入上核对梯度、实际更新和参数差分，再验证恢复后的模型输出。
若某一环异常，就针对该环定位；暂不从大梯度直接推断模型没有学习。

证据：左图为一 9B SFT（约 90 亿参数、监督微调起点）运行的全部 50 次优化记录。点是裁剪前梯度范数，表示反向传播信号的大小；纵轴采用对数刻度。虚线 1 是配置的裁剪阈值，不是判定训练健康的阈值。NaN 指非数值，这条运行的 50 次记录均不是 NaN，也不是无穷大。
判断边界：134 至 8.4×10^{11} 的范围提示需要验证更新，但梯度大小本身不能证明更新错误，更不能证明分子质量升降。右侧虚线框是尚需补充的观测，框内箭头表示建议的核查顺序；不宣称已有参数差分结果，也不把范围差异归因于单个组件。
来源：9b-sft_20260909T071143Z/train.log，50 轮采样、每任务 2 条候选轨迹、每轮 1 次优化，真实 acquisition 奖励（预期改进评分）。完整记录与行号见 data/metrics.csv；该单次运行不代表所有 9B 模型。

图 2.3 | 奖励能否区分候选，是一个需要单独解决的问题

全零奖励组没有组内偏好信号；先解释它为什么出现，再决定如何增加有效反馈。



待区分的原因，而非既定诊断

- 候选没有被成功评估？
- 评估成功，但没有获得改进奖励？
- 候选过于相似，评分都相同？

↓ 用候选级记录回答，不能只看组均值

建议验证 | 尚未执行

补齐每条候选的有效性、评估状态、原始奖励，以及每组奖励的标准差。
先定位信号在哪一环消失，再选采样、评估或奖励的修法，并重测零组比例。

证据：每条运行包含 50 轮采样、每轮 2 个任务组，分母均为 100 组。每组的候选数为 K；U 为每轮优化次数。左图柱高是所有候选奖励都为零的组占比。右图三类零奖励原因是待验证的候选解释，并非已经测出的比例；箭头表示需要补充日志来区分它们。

定义与判断边界：9B SFT 为约 90 亿参数、监督微调起点；组相对优化使用同组候选间的奖励差异，全零组没有这种偏好信号。两条都是 acquisition 奖励（预期改进评分），但 K 与 U 同时变化，各仅一次运行；K=8 的梯度还全部为 NaN（非数值）。因此较少全零组不能等同于成功优化或分子质量提升；奖励不全为零的组也不保证所有候选都有可用差异。

来源：9b-sft_20260909T071143Z 与 k8sft_20260909T200313Z 的 train.log。用逐轮 count_no_gradient 计数，并与正计数上的 count_lt_eps、count_0.0 核对；分别为 49/100 和 9/100。完整数据见 data/evidence.json。

图 2.4 | 49% 与 9% 的差异，还不能单独归因于候选数 K

现有比较同时改变候选数和更新次数；补一条短运行，也不能自动得到完整对照。



建议验证 | 尚未执行

奖励诊断：冻结同一模型与环境状态，只改变 K，重复采样看可区分性。
学习收益：待训练可靠后，固定 U 与评测预算比较 K，并明确匹配的训练资源口径。

读图：横轴 K 是每个任务的候选轨迹数，纵轴 U 是每轮采样的优化次数。框内比例是全零奖励组占比，括号给出实际计数。蓝框是各有 50 轮的两条运行，橙框只有 29 轮，灰色虚线框表示本次选定证据中缺少该格。斜箭头连接原先的两条比较：跨行又跨列，所以同时改变了 K 和 U。

范围与定义：均为 9B SFT（约 90 亿参数、监督微调起点）、真实 acquisition 奖励（预期改进评分），每轮 2 个任务组。这不是完整析因实验，也不声称其他目录里从未跑过缺失配置。组计数不是独立重复；50 轮的 K=2 与 K=8 分别生成 200 和 800 条候选轨迹，不能据此比较采样效率。

来源：9b-sft_20260909T071143Z（49/100）、9b-sft-gbs2_20260909T094256Z（37/58）、k8sft_20260909T200313Z（9/100）的逐轮计数。图下两个验证方案尚未执行；即使计数发生在本轮更新之前，此前的更新仍可能影响后续轮次，不能自动消除 U 的影响。

图 2.5 | 只有同预算的搜索结果，才能支持“RL 比 SFT 更好”

把技术修复收束到同一个问题：相同评估资源下，模型能否找到更好的分子？



建议验证 | 尚未执行

先锁定搜索预算的计数口径和对照协议，再评估通过训练验收的模型。
只有同预算 HV 的比较支持收益时，才报告效果提升；迁移结论单独检验。

读图：两个评测分支分别回答同目标效果与迁移效果。每个框内都要求 SFT-only（仅监督微调）与 SFT+RL（继续强化学习）比较；下方框是判定收益的共同要求，连线只表示两条分支都受此约束。灰色虚线表示尚缺可比结果，不代表分数为 0。

协议：训练目标为 KRAS G12D；G12C 是另一 KRAS 突变体，作为迁移评测。两者用各自的活性模型，共用 8UN5 对接受体。按原训练计划，每种策略、每个目标采用 5 个随机种子，搜索预算 80；HV（Pareto 超体积）衡量对接与活性两项目标的综合搜索结果，越高越好。建议配对种子、固定超体积参照点，报告每个种子的差值和不确定性；这些补充是拟议的比较规则，不是已跑结果。

证据范围：TRAINING_PLAN.md、2026-09-05 主目标审计、截至 09-10 的运行记录及 PR 2/5/6 后续讨论，结合 09-19 对 ldm_rl/results 清单的核查，未找到完整可比结果；不是全服务器普查。仅在 G12D 上有收益不能据此宣称 G12C 迁移成功；有限梯度或奖励升高也不能替代 HV 对照。